

Математика обучения нейронных сетей

От backpropagation до геометрии минимума функции потерь — и её связи с adversarial-уязвимостью

ЛЕКЦИЯ 2

КУРС ПО РОБАСТНОСТИ НЕЙРОННЫХ СЕТЕЙ

Цель лекции

Математический аппарат

Дать строгий математический аппарат обучения нейронных сетей — от вывода алгоритма обратного распространения ошибки до современных оптимизаторов и методов регуляризации.

Ключевая идея лекции

Показать, что геометрия найденного минимума функции потерь — её «острота» или «плоскость» — напрямую определяет чувствительность модели к возмущениям входа. Это формирует математический мост между классической проблемой переобучения и adversarial-уязвимостью, разбираемой в последующих лекциях курса.

Структура лекции

01

Вычислительный граф и backpropagation

02

Оптимизаторы: SGD → Adam

03

Регуляризация

04

Геометрия минимума


05

Связь с adversarial-уязвимостью

РАЗДЕЛ 1

Вычислительный граф и backpropagation

Формальная постановка задачи прямого прохода и вывод алгоритма обратного распространения ошибки через цепное правило дифференцирования.



Прямой проход: формализм

Рассмотрим сеть с **L слоями**. Для слоя l прямой проход задаётся следующими уравнениями:

$$z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}, \quad a^{(l)} = f(z^{(l)})$$

Обозначения

- f — функция активации (ReLU, sigmoid, tanh и др.)
- $\mathbf{a}^{(0)} = \mathbf{x}$ — вход сети
- $\mathbf{a}^{(L)}$ — выход сети (предсказание)
- $\mathbf{W}^{(l)}, \mathbf{b}^{(l)}$ — матрица весов и вектор смещений слоя l


Функция потерь

Функция потерь $L(a^{(L)}, y)$ сравнивает предсказание с истинной меткой.

Для задачи классификации типично используется **кросс-энтропия**:

$$L = - \sum_c y_c \log a_c^{(L)}$$

Цель обучения — минимизировать L по параметрам $\theta = \{W^{(l)}, b^{(l)}\}$.



Алгоритм backpropagation: вывод

Обратное распространение ошибки основано на **цепном правиле дифференцирования**. Введём «ошибку слоя» $\delta^{(l)} = \partial L / \partial z^{(l)}$.

Выходной слой

$$\delta^{(L)} = \nabla_{a^{(L)}} L \odot f'(z^{(L)})$$

где $\odot$ — покомпонентное произведение (Hadamard product).
Градиент потерь по активациям умножается поэлементно на производную функции активации.

Скрытые слои: рекуррентная формула

$$\delta^{(l)} = ((W^{(l+1)})^T \delta^{(l+1)}) \odot f'(z^{(l)})$$

Ошибка распространяется назад через транспонированную матрицу весов следующего слоя, умноженную на производную активации текущего слоя.

Градиенты по параметрам

$$\frac{\partial L}{\partial W^{(l)}} = \delta^{(l)} (a^{(l-1)})^T, \quad \frac{\partial L}{\partial b^{(l)}} = \delta^{(l)}$$

Градиенты по весам и смещениям получаются напрямую из вычисленных $\delta^{(l)}$ без дополнительных вычислений.

Вычислительная эффективность backprop

Ключевое преимущество

Алгоритм экономит вычисления за счёт **повторного использования промежуточных величин** $\delta^{(l)}$. Каждая величина вычисляется ровно один раз и используется при вычислении градиентов для всех нижележащих слоёв.


Сложность

Backprop

$O(P)$ — линейная по числу параметров P

Наивное дифференцирование

$O(2P)$ конечных разностей
— практически неприменимо



📌 Линейная сложность backprop — фундаментальная причина, по которой обучение глубоких сетей с миллиардами параметров стало практически возможным.



РАЗДЕЛ 2

Оптимизаторы: от SGD до Adam

Базовые и адаптивные методы оптимизации — и их влияние на геометрию найденного минимума.

Базовый градиентный спуск и SGD

Базовый градиентный шаг для параметров θ на итерации t :

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

Полный градиентный спуск (GD)

Вычисляет градиент по **всей обучающей выборке**.

Детерминированная траектория, высокая точность градиента, но огромные вычислительные затраты на каждом шаге при больших датасетах.

Стохастический градиентный спуск (SGD)

Заменяет полный градиент на **градиент по мини-батчу**. Вносит дополнительный шум в траекторию оптимизации, что эмпирически способствует нахождению более широких («плоских») областей минимума за счёт эффекта **неявной регуляризации**. [1][2]

Параметр η — **скорость обучения (learning rate)** — один из наиболее критичных гиперпараметров: слишком большой приводит к расходимости, слишком малый — к медленной сходимости или застреванию в локальных минимумах.

Метод импульса (Momentum)

$$v_{t+1} = \beta v_t + (1 - \beta) \nabla_{\theta} L(\theta_t), \quad \theta_{t+1} = \theta_t - \eta v_{t+1}$$


Идея метода

Momentum **накапливает историю градиентов** в виде экспоненциально взвешенного скользящего среднего v_t . Параметр $\beta \in [0, 1)$ (типично 0.9) контролирует «инерцию» — насколько сильно учитываются прошлые градиенты.

Эффекты

- **Сглаживание траектории** — уменьшение осцилляций в направлениях с переменным знаком градиента
- **Ускорение сходимости** в направлениях с устойчивым градиентом
- Помогает «перепрыгивать» через узкие барьеры в пространстве потерь

Vanilla SGD barely moves; Momentum reaches the valley



Оптимизатор Adam

Adam (**Adaptive Moment Estimation**) комбинирует адаптивные оценки первого и второго момента градиента:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t, \quad v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}, \quad \theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

Компоненты

- **m_t** — первый момент (среднее градиентов), аналог momentum
- **v_t** — второй момент (дисперсия градиентов), адаптивный масштаб
- **Коррекция смещения** $\hat{m}_t, \hat{v}_t$ — компенсирует инициализацию нулями
- Типичные значения: $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$

Критически важное свойство

Адаптивная нормировка по $\sqrt{\hat{v}_t}$ ускоряет обучение по направлениям с малой дисперсией градиента. Однако по этой же причине **Adam чаще сходится к более «острым» минимумам** по сравнению с SGD с большим шумом мини-батчей — эмпирический факт, принципиально важный для дальнейшего обсуждения связи оптимизатора и устойчивости модели. [1]

Сравнение оптимизаторов

GD

Точный градиент, детерминированная траектория. Медленно, неприменимо к большим данным. Острые минимумы.

SGD

Шум мини-батчей → неявная регуляризация → **плоские минимумы**. Лучшее обобщение, но медленная сходимость.


SGD + Momentum

Быстрее SGD, сглаженная траектория. Сохраняет тенденцию к плоским минимумам при правильном LR.

Adam

Быстрая сходимость, адаптивный LR. Тяготеет к **острым минимумам** — хуже обобщение и устойчивость.

📌 Выбор оптимизатора — это не только вопрос скорости сходимости, но и вопрос геометрии найденного решения и его устойчивости к возмущениям.



РАЗДЕЛ 3

Регуляризация: математические формулировки

L2-регуляризация, Dropout и Batch Normalization — три ключевых инструмента ограничения ёмкости модели и предотвращения переобучения.

L2-регуляризация (Weight Decay)

L2-регуляризация добавляет штраф на норму весов к функции потерь:

$$\tilde{L}(\theta) = L(\theta) + \frac{\lambda}{2} \|\theta\|_2^2$$

Модифицированное правило обновления

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta\nabla_{\theta}L(\theta_t)$$

Множитель $(1 - \eta\lambda)$ **сжимает веса к нулю** на каждом шаге независимо от градиента потерь. Это ограничивает эффективную ёмкость модели, не позволяя весам принимать произвольно большие значения.

Интерпретации

- **Байесовская:** L2-регуляризация эквивалентна MAP-оценке с гауссовским априорным распределением на веса
- **Геометрическая:** ограничивает решение на шар радиуса $1/\sqrt{\lambda}$ в пространстве параметров
- **Оптимизационная:** смещает минимум в сторону меньших норм весов, что коррелирует с более плоскими минимумами

Dropout

Dropout на этапе обучения случайно зануляет активации слоя с вероятностью p :

$$\tilde{a}^{(l)} = a^{(l)} \odot m^{(l)}, \quad m_i^{(l)} \sim \text{Bernoulli}(1 - p)$$

Механизм действия

На каждом шаге обучения случайно выбранная доля p нейронов «отключается» (их активации обнуляются). На этапе инференса все нейроны активны, но их выходы масштабируются на $(1 - p)$.

Теоретическая интерпретация

Dropout эквивалентен **неявному ансамблированию** экспоненциального числа подсетей (2^n для n нейронов). Это предотвращает **чрезмерную специализацию** отдельных нейронов на конкретных обучающих примерах — явление, называемое co-adaptation.

Случайное отключение нейронов вынуждает сеть учиться **избыточные, независимые признаки**, что повышает устойчивость представлений.

Batch Normalization

Batch Normalization нормирует активации внутри мини-батча:

$$\hat{z} = \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y = \gamma \hat{z} + \beta$$

Параметры


- μ_B, σ_B^2 — среднее и дисперсия активаций по мини-батчу
- γ, β — **обучаемые** параметры масштаба и сдвига
- ϵ — малая константа для численной стабильности

Эффекты BatchNorm

- **Ускорение сходимости** — позволяет использовать более высокие learning rate
- **Уменьшение зависимости** от инициализации весов
- **Неявная регуляризация**: BatchNorm вносит стохастический шум, зависящий от состава батча — аналогично SGD-шуму, это смещает оптимизацию в сторону более плоских минимумов

📌 Все три метода регуляризации — weight decay, dropout, BatchNorm — помимо борьбы с переобучением, неявно смещают оптимизацию к более плоским минимумам функции потерь.

Loss Landscape: SmoLM2



РАЗДЕЛ 4

Геометрия минимума функции потерь

Локальная кривизна функции потерь в найденной точке минимума — ключ к пониманию обобщающей способности и устойчивости модели.

Разложение Тейлора и матрица Гессе

Ключевая связь между переобучением и уязвимостью строится через **локальную кривизну функции потерь** в найденной точке минимума θ^* . Разложение в ряд Тейлора второго порядка:

$$L(\theta^* + \Delta\theta) \approx L(\theta^*) + \nabla L(\theta^*)^T \Delta\theta + \frac{1}{2} \Delta\theta^T H \Delta\theta$$

Матрица Гессе H

$H = \nabla_{\theta}^2 L(\theta^*)$ — матрица вторых производных функции потерь в точке минимума. В точке минимума $\nabla L(\theta^*) = 0$, поэтому линейный член обращается в ноль, и **чувствительность потерь к возмущению параметров полностью определяется собственными значениями H**.

Интерпретация собственных значений

- **Большие собственные значения H** $\rightarrow$ «острый» (sharp) минимум: малое возмущение $\Delta\theta$ резко увеличивает потери
- **Малые собственные значения H** $\rightarrow$ «плоский» (flat) минимум: устойчив к возмущениям параметров [3][1]

Острые и плоские минимумы



Острый минимум (Sharp)

Большие собственные значения матрицы Гессе. Малое возмущение параметров $\Delta\theta$ приводит к резкому росту функции потерь. Модель «запомнила» тренировочные данные через узкую, нестабильную конфигурацию весов.

- Плохое обобщение на тестовые данные
- Высокая чувствительность к adversarial-атакам
- Характерен для Adam, больших батчей

Плоский минимум (Flat)

Малые собственные значения матрицы Гессе. Параметры можно возмущать без значительного роста функции потерь. Модель нашла широкую, устойчивую конфигурацию весов.

- Хорошее обобщение на тестовые данные
- Устойчивость к adversarial-возмущениям
- Характерен для SGD с малыми батчами [4][2]

Плоские минимумы и обобщение

Эмпирическая корреляция

Плоские минимумы эмпирически коррелируют с **лучшей обобщающей способностью**: если параметры можно возмущать без значительного роста тренировочной ошибки, то небольшое расхождение между тренировочным и тестовым распределением данных не приводит к катастрофическому падению точности. [4] [2]

Интерпретация через margin

В плоском минимуме класс-разделяющие границы находятся на «безопасном» расстоянии от тренировочных точек. Небольшое смещение границы (вызванное отличием тестового распределения) не меняет классификацию соседних точек.

Почему регуляризация помогает

Это объясняет, почему методы регуляризации систематически смещают оптимизацию в сторону более широких минимумов:



Weight decay

Ограничивает норму весов → меньшая кривизна



Dropout

Ансамблирование подсетей → усреднение по широкой области



SGD-шум

Стохастические градиенты → «выбивание» из острых минимумов

РАЗДЕЛ 5


Связь остроты минимума с adversarial-уязвимостью

Математический мост между геометрией пространства параметров и чувствительностью модели к целенаправленным возмущениям входа.



PANDA

+



NOISE

=



GIBBON

Adversarial Risk: формальное определение

Хотя острота минимума формально определена в пространстве параметров θ , она тесно связана с чувствительностью модели к возмущениям входа x . Формально, **adversarial risk** модели определяется как:

$$\mathcal{R}_{adv}(\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\max_{\|\delta\| \leq \epsilon} L(\theta, x + \delta, y) \right]$$


Интерпретация

Adversarial risk — это ожидаемые потери при **наихудшем возмущении входа** в пределах шара радиуса ϵ . Модель считается adversarially robust, если это значение мало — то есть даже при оптимально подобранном возмущении входа потери остаются низкими.

Связь с геометрией

Исследования показывают устойчивую корреляцию между «**плоскостью**» **минимума** в пространстве весов при adversarial training и меньшим разрывом между robust-точностью на обучающей и тестовой выборках — так называемым **robust overfitting**. [5][6]

Robust Overfitting



Определение

Модели, найденные в более **острых минимумах**, демонстрируют значительно больший разрыв между точностью на тренировочных adversarial-примерах и тестовых — то есть их устойчивость **плохо обобщается** на новые атаки, даже если формально они «выучили» защиту от конкретных атакующих примеров в обучающей выборке. [5] [6][7]

Robust Generalization Gap

$$\text{Gap}_{adv} = \mathcal{R}_{adv}^{test}(\theta) - \mathcal{R}_{adv}^{train}(\theta)$$

Этот разрыв эмпирически коррелирует с обычным переобучением и усиливается при использовании оптимизаторов и режимов обучения, тяготеющих к острым минимумам: большие батчи, недостаточная регуляризация, чрезмерно долгое обучение без early stopping.

Геометрическая интуиция: margin и решающие границы

Плоский минимум

Класс-разделяющие границы находятся на **«безопасном» расстоянии** от тренировочных точек. Небольшое смещение границы (вызванное отличием тестового распределения либо целенаправленным adversarial-возмущением входа) **не меняет классификацию** соседних точек. Широкий margin → устойчивость.

Острый минимум

Границы проходят **близко к тренировочным примерам**. Даже малое возмущение — входа или самих весов — способно вызвать неверную классификацию. Узкий margin → уязвимость к adversarial-атакам. [4]

Это даёт математическое основание для методов, изучаемых в лекции 12: **adversarial training** и **sharpness-aware minimization (SAM)** — явное принуждение оптимизации к плоским минимумам одновременно улучшает как классическое обобщение, так и устойчивость к adversarial-атакам. [2][8][5][4]


Визуализация: острые vs. плоские минимумы

Острый минимум [5]

Большие изменения в ландшафте функции потерь вокруг «острого» минимума вызывают **плохое обобщение robust-точности**. Модель, обученная adversarial training в таком минимуме, демонстрирует высокую robust-точность на тренировочных данных, но низкую — на тестовых.

Плоский минимум [5]


Малые изменения в ландшафте вокруг «плоского» минимума обеспечивают **хорошее обобщение robust-точности**. Разрыв между тренировочной и тестовой robust-точностью минимален — модель действительно «выучила» устойчивые признаки, а не запомнила конкретные атаки.



РАЗДЕЛ 6

Переобучение как источник уязвимости

Итоговая интерпретация: классическое переобучение и adversarial-уязвимость — два проявления одной структурной проблемы.



Классический и robust generalization gap

Классический generalization gap

$$\text{Gap} = \mathcal{R}_{test}(\theta) - \mathcal{R}_{train}(\theta)$$

Разрыв между тренировочной и тестовой ошибкой.
Классическая мера переобучения — модель «запомнила» тренировочные данные вместо того, чтобы выучить обобщаемые закономерности.

Robust generalization gap

$$\text{Gap}_{adv} = \mathcal{R}_{adv}^{test}(\theta) - \mathcal{R}_{adv}^{train}(\theta)$$

Разрыв между adversarial-точностью на тренировочных и тестовых данных. Эмпирически **коррелирует с обычным переобучением** и усиливается теми же факторами: большие батчи, недостаточная регуляризация, чрезмерно долгое обучение без early stopping. [7][9][8][5]

Факторы, усиливающие оба вида гар



Большие батчи

Уменьшают шум SGD → детерминированная траектория → острые минимумы → плохое обобщение и высокая adversarial-уязвимость.



Недостаточная регуляризация

Отсутствие weight decay, dropout → модель свободно запоминает тренировочные примеры → острые, узкие минимумы.



Долгое обучение без early stopping

Модель продолжает «углублять» острые минимумы после достижения оптимального обобщения → нарастание обоих видов гар.



Адаптивные оптимизаторы (Adam)

Быстрая сходимость к острым минимумам → хорошая тренировочная точность, но плохое обобщение и устойчивость.

Единая структурная проблема

Переобучение — это не только классическая проблема «плохого обобщения на новые данные», но и **структурный источник уязвимости**: модель, запомнившая тренировочные примеры через острые, узкие минимумы, одновременно хуже обобщается и легче обманывается целенаправленными adversarial-возмущениями. [7][9][8][5]



Современная литература: подтверждения (2024–2025)

Visualizing the Loss Landscape of Neural Nets [1]

Малые батчи SGD производят «плоские» минимумы с лучшим обобщением. Визуализация ландшафта потерь подтверждает качественное различие между острыми и плоскими минимумами.

Relating Adversarially Robust Generalization to Flat Minima [5][6]

Adversarial training демонстрирует severe robust overfitting. Плоскость минимума в пространстве весов при adversarial training коррелирует с меньшим разрывом robust-точности.

Fast adversarial training based on implicit sharpness aware minimization [8]


Установлена новая связь между острыми минимумами в пространстве весов и катастрофическим overfitting при adversarial training. SAM-подходы улучшают оба вида обобщения.

Fantastic Robustness Measures [9]

Adversarial training стал де-факто стандартом улучшения робастности. Меры плоскости минимума входят в число наиболее предсказательных метрик robust generalization.

Практический вывод: регуляризация как защита

Методы регуляризации, изучаемые в классическом ML как средство против переобучения, являются одновременно **первой линией защиты против adversarial-уязвимости**.



Регуляризация: двойная роль



Weight Decay

Классически: ограничивает переобучение. Дополнительно: сжимает веса → меньшая кривизна Гессе → более плоский минимум → лучшая adversarial-устойчивость.



Dropout

Классически: предотвращает co-adaptation нейронов. Дополнительно: ансамблирование подсетей → усреднение по широкой области пространства параметров → плоский минимум.



Early Stopping

Классически: останавливает обучение до переобучения. Дополнительно: предотвращает «углубление» острых минимумов → сохраняет плоскость найденного решения.



Малый размер батча

Классически: вычислительная эффективность. Дополнительно: большой SGD-шум → неявная регуляризация → плоские минимумы → лучшее обобщение и устойчивость. [1][2]

Связь с лекцией 12: SAM и Adversarial Training

Sharpness-Aware Minimization (SAM)

SAM явно минимизирует не только значение функции потерь, но и её **чувствительность к возмущениям параметров**:

$$\min_{\theta} \max_{\|\epsilon\| \leq \rho} L(\theta + \epsilon)$$

Это прямое принуждение к плоским минимумам. SAM одновременно улучшает классическое обобщение и adversarial-устойчивость — математическое следствие единой природы обеих проблем. [8][2]

Adversarial Training

Adversarial training минимизирует adversarial risk напрямую, обучая на наихудших возмущениях входа. Исследования показывают, что adversarial training в сочетании с методами, смещающими к плоским минимумам, значительно уменьшает robust overfitting — разрыв между тренировочной и тестовой robust-точностью. [5][6]

Детальное изучение этих методов — тема **лекции 12** курса.

Итоговая схема: от backprop до adversarial-устойчивости



Все пять тем лекции образуют единую цепочку: выбор оптимизатора и методов регуляризации определяет геометрию найденного минимума, которая в свою очередь определяет как классическое обобщение, так и adversarial-устойчивость модели.

Ключевые формулы лекции

Backpropagation

$$\delta^{(l)} = ((W^{(l+1)})^T \delta^{(l+1)}) \odot f'(z^{(l)})$$

Adam

$$\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

L2-регуляризация

$$\tilde{L}(\theta) = L(\theta) + \frac{\lambda}{2} \|\theta\|_2^2$$

Разложение Тейлора (кривизна)

$$L(\theta^* + \Delta\theta) \approx L(\theta^*) + \frac{1}{2} \Delta\theta^T H \Delta\theta$$

Adversarial Risk

$$\mathcal{R}_{adv}(\theta) = \mathbb{E} \left[\max_{\|\delta\| \leq \epsilon} L(\theta, x + \delta, y) \right]$$

Robust Generalization Gap

$$\text{Gap}_{adv} = \mathcal{R}_{adv}^{test}(\theta) - \mathcal{R}_{adv}^{train}(\theta)$$

1. <https://papers.neurips.cc/paper/7875-visualizing-the-loss-landscape-of-neural-nets.pdf>
2. [Loss Landscape Flatness in Deep Learning – Emergent Mind](#)
3. [Connection between Flatness and Generalization | Tuan-Anh Bui](#)
4. [Understanding generalization through visualization](#)
5. [ArXiv Pre-Print "Relating Adversarially Robust Generalization to Flat ...](#)
6. https://openaccess.thecvf.com/content/ICCV2021/papers/Stutz_Relating_Adversarially_Robust_Generalization_to_Flat_Minima_ICCV_2021_paper.pdf
7. [Understanding Adversarially Robust Generalization via Weight ...](#)
8. [Fast adversarial training based on implicit sharpness aware ...](#)
9. [Fantastic Robustness Measures: The Secrets of Robust Generalization](#)

Выводы и связь с курсом

1 Backpropagation — линейная сложность

Алгоритм обратного распространения ошибки через цепное правило обеспечивает линейную вычислительную сложность по числу параметров, делая обучение глубоких сетей практически возможным.

3 Регуляризация смещает к плоским минимумам

Weight decay, dropout, BatchNorm и early stopping — все они неявно смещают оптимизацию к более широким минимумам, улучшая обобщение.

2 Оптимизатор определяет геометрию

SGD с малыми батчами тяготеет к плоским минимумам; Adam — к острым. Выбор оптимизатора — это выбор компромисса между скоростью сходимости и качеством обобщения.

4 Переобучение = adversarial-уязвимость

Острые минимумы одновременно порождают классический и robust generalization gap. Регуляризация — первая линия защиты против adversarial-атак. Детальное развитие — в **лекции 12** (adversarial training, SAM) и **лабораторной работе к лекции 2**.

📌 Практический вывод: методы регуляризации, изучаемые как средство против переобучения, являются одновременно первой линией защиты против adversarial-уязвимости — это будет проверено экспериментально в лабораторной работе.