


Итеративные и оптимизационные атаки: PGD, C&W, JSMA

Три класса методов adversarial-атак, преодолевающих ограничения одношагового FGSM: многошаговый PGD, оптимизационная C&W и разреженная JSMA.



На предыдущей лекции

Ограничение FGSM

Одношаговый Fast Gradient Sign Method решает лишь **линеаризованную аппроксимацию** задачи максимизации потерь и не учитывает кривизну (гессиан) решающей поверхности. Это означает, что FGSM даёт лишь **нижнюю оценку** силы возможной атаки.

Эмпирическое превосходство PGD

При одинаковом бюджете ϵ итеративный PGD достигает Attack Success Rate на **30–60 процентных пунктов выше**, чем FGSM. Это делает переход к многошаговым и оптимизационным атакам логичным развитием темы.

Три направления ответа

- **PGD** — многошаговое обобщение линейной атаки с проекцией
- **C&W** — строгая оптимизационная постановка минимальной дисторсии
- **JSMA** — якобиан выхода сети и точечное (sparse) изменение признаков

От FGSM к итеративным атакам: постановка задачи

Любая evasion-атака в белом ящике решает задачу **максимизации функции потерь** модели при ограничении на возмущение:

$$\max_{|\eta|_p \leq \epsilon} J(\theta, x + \eta, y)$$

Подход FGSM


FGSM аппроксимирует задачу линеаризацией:

$$J(\theta, x + \eta, y) \approx J(\theta, x, y) + \nabla_x J(\theta, x, y)^T \eta$$

и решает получившуюся линейную задачу аналитически за **один шаг**.

Почему этого недостаточно

Точность аппроксимации падает по мере роста ϵ и кривизны функции потерь. Естественное обобщение — заменить один шаг **серией малых шагов**, пересчитывая градиент на каждой итерации и проецируя результат обратно в допустимую область.



Projected Gradient Descent: формальное определение

PGD — итеративный метод построения adversarial-примеров, на каждой итерации которого выполняется **шаг градиентного подъёма по знаку градиента** с последующей проекцией результата на допустимое множество (обычно ϵ -шар в норме L_∞). Формула обновления:

$$x^{t+1} = \Pi_{x+\mathcal{S}}(x^t + \alpha \cdot \text{sign}(\nabla_x L(\theta, x^t, y)))$$

Компоненты формулы

- $\mathcal{S}$ — допустимое множество возмущений ($|\eta|_\infty \leq \epsilon$)
- α — величина шага
- Π — оператор проекции, возвращающий точку в границы ϵ -шара и в диапазон $[0, 1]$

Проекция на L_∞ -шар (clipping)

$$\text{clip}_i(\eta_i) = \begin{cases} -x_i, & \eta_i < -x_i \\ \eta_i, & \eta_i \in [-x_i, 1 - x_i] \\ 1 - x_i, & \eta_i > 1 - x_i \end{cases}$$

Одновременно ограничивает возмущение бюджетом ϵ и удерживает пиксель в диапазоне $[0, 1]$

Инициализация и роль случайного старта

Зачем нужен случайный старт

Важным элементом практической реализации PGD является **случайная инициализация** внутри ϵ -шара перед первой итерацией, а не старт из исходной точки x . Это предотвращает эффект **«ложной устойчивости»**: если начинать строго из x , обучение модели может подстроиться так, что градиент именно в этой точке указывает в «пологом» направлении, тогда как рядом лежат более крутые направления атаки.

Псевдокод реализации

```
delta = random_uniform(-epsilon, epsilon)
for t in range(num_iter):
    loss = criterion(
        model(x + delta), y)
    loss.backward()
    delta = clip(
        delta + alpha * sign(delta.grad),
        -epsilon, epsilon)
    delta.grad.zero_()
```

PGD как «универсальный первопорядковый противник»

Формулировка Мадри и соавторов (2018) трактует задачу adversarial-обучения как **седловую точку (saddle point problem)**:

$$\min_{\theta} \rho(\theta), \quad \rho(\theta) = \mathbb{E}_{(x,y) \sim \mathcal{D}} \left[\max_{\delta \in \mathcal{S}} L(\theta, x + \delta, y) \right]$$

Структура задачи

- **Внутренняя максимизация** — задача атаки
- **Внешняя минимизация по θ** — обучение устойчивой модели

По теореме Данскина, градиент внешней задачи сводится к градиенту в точке найденного максимума:

$$\nabla_{\theta} \max_{\delta \in \mathcal{S}} L(\theta, x + \delta, y) = \nabla_{\theta} L(\theta, x + \delta^*, y)$$

Ключевой вывод

Несмотря на **невыпуклость** обеих подзадач, PGD эмпирически находит достаточно качественные локальные решения внутренней максимизации. Модель, устойчивая к PGD-атаке, приобретает устойчивость и к другим атакам первого порядка (в том числе к FGSM) — отсюда термин **«Universal First-Order Adversary»**.

Практические характеристики PGD

80–90%

Attack Success Rate PGD

Заметно выше показателей FGSM при
большой вычислительной стоимости

70–80%

Attack Success Rate FGSM

Одношаговый метод, значительно уступает
PGD по эффективности

100+

Итераций PGD

Десятки или сотни пересчётов градиента для
достижения максимальной эффективности

Требования белого ящика

PGD относится к атакам **белого ящика**: для построения эффективной атаки требуется знание архитектуры модели, её параметров, функции потерь и способа нормализации входных данных.


Применение

PGD стал **стандартной атакой** для оценки состязательной устойчивости моделей и базовым инструментом adversarial training, а также применяется в адаптивных атаках против современных защитных механизмов.

Сравнение методов по Attack Success Rate

■ Минимум (%) ■ Максимум (%)

Метод




C&W

Атака Carlini & Wagner:

МОТИВАЦИЯ

C&W-атака, предложенная **Карлини и Вагнером в 2017 году**, переформулирует задачу поиска adversarial-примера принципиально иначе по сравнению с PGD.



От эвристики к строгой оптимизации

Подход PGD (эвристика)

Максимизация потерь при **фиксированном бюджете ε** . Ищет любую точку внутри ε -шара, максимизирующую потери.

Ограничение на норму — эвристическое.

Подход C&W (строгая оптимизация)

Минимизация нормы возмущения при **жёстком требовании ошибочной классификации**. Общая постановка (восходит к Szegedy et al., 2013):

$$\min_{x'} \|x' - x\|_p \text{ s.t. } f(x') \neq f(x), \quad x' \in [0, 1]^n$$

Такая формулировка исторически решалась через box-constrained L-BFGS. C&W развивает эту идею с более эффективными инструментами.

Замена ограничения специальной функцией потерь

Прямое ограничение «модель ошибается» плохо приспособлено для градиентной оптимизации, поэтому C&W заменяют его специально сконструированной функцией f , которая становится **отрицательной (или равной нулю)** именно тогда, когда цель атаки достигнута.

Итоговая безусловная задача:

$$\min_{\delta} |\delta|_p + c \cdot f(x + \delta)$$

Параметр c

Регулирует **баланс** между малостью возмущения и силой ошибки классификации. Подбирается внешним бинарным поиском.

Функция f

Специально сконструирована так, чтобы быть **дифференцируемой** и обращаться в ноль или отрицательное значение при достижении целевой ошибочной классификации.

Функция потерь на логитах и параметр уверенности κ

Для целевой атаки на класс t авторы предлагают функцию, работающую на **логитах** $Z(x')$ (выходах до softmax):

$$f(x') = \max \left(\max_{i \neq t} Z(x')_i - Z(x')_t, -\kappa \right)$$

Смысл формулы

Находится наибольший логит среди всех классов, отличных от целевого, и требуется, чтобы логит целевого класса **превышал его с запасом не менее κ** .

Роль параметра κ («confidence»)

- При **$\kappa = 0$** : достаточно, чтобы целевой логит был просто наибольшим
- При **$\kappa = 40$** : модель классифицирует adversarial-пример с высокой уверенностью
- Большие κ существенно повышают устойчивость атаки к защитным методам вроде **дефенсивной дистилляции**

Замена переменных через tanh

Чтобы гарантировать, что итоговое изображение $x' = x + \delta$ остаётся в допустимом диапазоне $[0,1]$ без явного clipping (который мешает градиентной оптимизации), C&W применяют **замену переменных через гиперболический тангенс**:

$$x' = \frac{1}{2}(\tanh(w) + 1)$$

Преимущество подхода

Оптимизация ведётся по **неограниченной переменной** w , а результат автоматически попадает в $[0,1]$. Итоговая целевая функция L_2 – варианта атаки:

$$\min_w \left| \frac{1}{2}(\tanh(w) + 1) - x \right|_2^2 + c \cdot f \left(\frac{1}{2}(\tanh(w) + 1) \right)$$

Три варианта по норме

L_0

Число изменённых пикселей


L_2

Наиболее распространённый и изученный вариант

L_∞


Максимальное изменение пикселя

C&W vs PGD: сравнение подходов



PGD

Ищет **любую точку** внутри фиксированного ϵ -шара, максимизирующую потери. Быстрее, но возмущение может быть больше необходимого.



C&W

Напрямую минимизирует величину искажения, что обычно даёт значительно менее заметные (по норме) возмущения. Требует решения более тяжёлой задачи через Adam с внешним бинарным поиском по константе c .

📌 C&W-атака остаётся одним из наиболее сильных известных методов белого ящика и специально конструировалась как контрпример к дефенсивной дистилляции — защите, которую она успешно обходит.

Меры противодействия C&W

Adversarial Training

Включение сгенерированных C&W-примеров в обучающую выборку для повышения устойчивости модели.

Входные преобразования

Сжатие JPEG, снижение битовой глубины, пространственное сглаживание — разрушают тонкую структуру adversarial-возмущения.

Ансамблевые методы

Требование консенсуса нескольких разнородных моделей затрудняет одновременный обман всех компонентов ансамбля.

Сертифицированные защиты

Randomized smoothing, interval bound propagation — дают **формально доказуемые гарантии** устойчивости. Ни один метод не показал полной устойчивости к C&W.



The 10 Layers of Cyber Defense




- 1 IAM Controls who gets access
- 2 Firewalls Guard your perimeter
- 3 EDR & NDR Track suspicious internal activity
- 4 IDS/IPS Block active threats in real time
- 5 SIEM Connect and prioritize alerts
- 6 Cloud Security Protect hybrid workloads
- 7 DLP Stop data leakage
- 8 Incident Resp Contain and recover
- 9 Awareness Train users to avoid mistakes

JSMA

Jacobian-based Saliency Map Attack: идея

JSMA — семейство атак, принципиально отличающихся от FGSM и PGD по механизму воздействия на входные данные.



Отличие JSMA от градиентных атак

FGSM / PGD

Изменяют **все признаки входа одновременно**, распределяя возмущение по всему изображению. Используют градиент функции потерь по входу.

JSMA

Точечно модифицирует **минимальное число пикселей**, доводя их значения до предельных (максимум или минимум допустимого диапазона), чтобы вызвать неверную классификацию с заданным целевым классом. В основе метода лежит не градиент функции потерь по входу, а **якобиан выходного вектора модели** (вектора логитов или вероятностей классов) по входным признакам.

Прямая производная и якобиан

Прямая производная модели F определяется как якобиан отображения «вход $\rightarrow$ вектор выходов по классам»:

$$\nabla F(x) = \left[\frac{\partial F_i(x)}{\partial x_j} \right]$$

Вычисление

Якобиан вычисляется **один раз** для входного примера и используется затем для построения карты значимости (saliency map) каждого признака относительно каждого класса.

Преимущество перед backprop по потерям

Использование прямой производной позволяет напрямую оценить, как изменение конкретного пикселя повлияет на вероятность **каждого отдельного класса**, а не только на итоговую скалярную потерю.

Оптимизационная задача JSMA

Формальная постановка задачи атаки:

$$\arg \max_{\sigma_a} |\sigma_a| \text{ s.t. } F(x + \sigma_a) = y^*$$

где σ_a — вектор точечного возмущения, y — требуемый (целевой) выход модели.

Принцип выбора признаков

Алгоритм итеративно выбирает **пару признаков (или один признак)** с наибольшим значением saliency-карты — тех, чьё изменение максимально увеличивает вероятность целевого класса при минимальном влиянии на вероятности остальных классов.

Насыщение значений

Выбранные признаки **насыщаются (saturate)** до предельного уровня — максимального или минимального допустимого значения. Это принципиально отличает JSMA от методов, добавляющих малое возмущение.

Практическая процедура JSMA



Процедура повторяется до достижения требуемой целевой классификации или исчерпания бюджета изменений.

Вычислительная стоимость и оптимизации


Квадратичная сложность

Оригинальный алгоритм имеет вычислительную сложность $O(M^2 \times N)$ относительно размерности входа, что делает его крайне ресурсоёмким и практически неприменимым для датасетов высокого разрешения типа ImageNet.

FastJSMA

Современные работы (например, **FastJSMA**) предлагают приближения, снижающие сложность до $O(M\sqrt{N})$, сохраняя порядка **98% относительной эффективности** атаки при кратном ускорении. Это делает метод применимым к более широкому кругу задач.

Значение JSMA для интерпретируемости



Ключевое практическое преимущество JSMA — **интерпретируемость**: поскольку атака модифицирует явно ограниченный, часто очень небольшой набор признаков, результат легко визуализировать и анализировать в контексте того, какие именно входные признаки модель считает наиболее «уязвимыми» для данного класса.

L_0 -норма как естественная метрика


В отличие от PGD и C&W, которые работают с нормами L_∞ или L_2 и распределяют возмущение по всему входу, JSMA по своей природе тяготеет к **L_0 -норме** (число изменённых признаков).

Релевантные домены

L_0 -подход особенно актуален там, где именно **число модифицированных признаков** (а не их суммарная величина) является практическим ограничением атакующего:

- Атаки на **табличные данные**
- Системы **обнаружения вторжений**
- Домены с дискретными признаками

Сравнительная сводка: тип оптимизации



Сравнительная сводка: используемая информация

PGD

Градиент функции потерь по входу — скалярная информация о направлении наибольшего роста потерь

C&W


Логиты модели и специальная функция f — прямой доступ к выходам до softmax для точного управления уверенностью

JSMA

Якобиан вектора выходов по входу — полная матрица частных производных каждого выхода по каждому признаку

Сравнительная сводка: типичная норма возмущения


PGD (Projected Gradient Descent)



PGD (Projected Gradient Descent)

L-inf:
максимальное
изменение.
Обобщается на L_p .


C&W (Carlini & Wagner)



C&W (Carlini & Wagner)

Поддерживает L0,
L2, L-inf. L2
наиболее
распространена.


JSMA (Jacobian-based Saliency Map Attack)



JSMA (Jacobian-based Saliency Map Attack)

Фактически L0:
число изменённых
признаков.

Сравнительная сводка: вычислительная стоимость



Сравнительная сводка: основное применение



PGD

Adversarial training и оценка устойчивости. Стандартная атака для оценки состязательной устойчивости моделей. Применяется в адаптивных атаках против современных защитных механизмов.



C&W

Оценка предельной устойчивости и обход дистилляции. Один из главных эталонов при оценке новых защитных механизмов. Специально конструировалась против дефенсивной дистилляции.



JSMA

Интерпретируемые, разреженные атаки. Применяется в доменах, где число модифицированных признаков является практическим ограничением: табличные данные, системы обнаружения вторжений.

Полная сравнительная таблица

Критерий	PGD	C&W	JSMA
Тип оптимизации	Итеративный градиентный подъём с проекцией	Минимизация дисторсии при ограничении на ошибку	Итеративное насыщение признаков по якобиану
Используемая информация	Градиент функции потерь по входу	Логиты модели, специальная функция f	Якобиан вектора выходов по входу
Типичная норма	L^∞ (обобщается на L_p)	L_0, L_2, L^∞	Фактически L_0
Вычислительная стоимость	Высокая (десятки–сотни итераций)	Очень высокая (оптимизация + бинарный поиск)	Очень высокая, квадратичная по размерности
Основное применение	Adversarial training, оценка устойчивости	Оценка предельной устойчивости, обход дистилляции	Интерпретируемые, разреженные атаки

Ключевые формулы: итоговый обзор PGD

Шаг обновления

$$x^{t+1} = \Pi_{x+\mathcal{S}}(x^t + \alpha \cdot \text{sign}(\nabla_x L(\theta, x^t, y)))$$

Седловая задача (Мадри 2018)

$$\min_{\theta} \mathbb{E}_{(x,y)} \left[\max_{\delta \in \mathcal{S}} L(\theta, x + \delta, y) \right]$$

Теорема Данскина

$$\nabla_{\theta} \max_{\delta \in \mathcal{S}} L(\theta, x + \delta, y) = \nabla_{\theta} L(\theta, x + \delta^*, y)$$

Проекция (clipping)

$$\text{clip}_i(\eta_i) = \begin{cases} -x_i, & \eta_i < -x_i \\ \eta_i, & \eta_i \in [-x_i, 1 - x_i] \\ 1 - x_i, & \eta_i > 1 - x_i \end{cases}$$

Ключевые формулы: итоговый обзор C&W

Общая постановка

$$\min_{x'} |x' - x|_p \text{ s.t. } f(x') \neq f(x)$$

Безусловная задача

$$\min_{\delta} |\delta|_p + c \cdot f(x + \delta)$$

Функция потерь на логитах

$$f(x') = \max \left(\max_{i \neq t} Z(x')_i - Z(x')_t, -\kappa \right)$$

Замена переменных (tanh)

$$\min_w \left| \frac{1}{2}(\tanh(w) + 1) - x \right|_2^2 + c \cdot f \left(\frac{1}{2}(\tanh(w) + 1) \right)$$

Ключевые формулы: итоговый обзор JSMA

Якобиан (прямая производная)

$$\nabla F(x) = \left[\frac{\partial F_i(x)}{\partial x_j} \right]$$

Оптимизационная задача

$$\arg \max_{\sigma_a} |\sigma_a| \text{ s.t. } F(x + \sigma_a) = y^*$$

Вычислительная сложность

Оригинал


$O(M^2 \times N)$ — квадратичная
по размерности входа

FastJSMA

$O(M\sqrt{N})$ — сохраняет ~98%
эффективности

Adversarial Training как главное применение PGD

PGD занимает центральное место в **adversarial training** — наиболее эффективном на сегодня методе повышения устойчивости нейронных сетей. Модель, обученная противостоять PGD-атаке, приобретает устойчивость и к другим атакам первого порядка. Именно поэтому PGD называют «универсальным первопорядковым противником».



Процедура adversarial training

1. Для каждого батча генерируются PGD-adversarial примеры
2. Модель обучается на смеси чистых и adversarial примеров
3. Внутренняя максимизация решается приближённо через PGD
4. Внешняя минимизация — стандартный SGD/Adam

Ограничения

Adversarial training существенно увеличивает **вычислительную стоимость** обучения (в 10–50 раз). Устойчивость к PGD не гарантирует устойчивости к атакам второго порядка или атакам с другими нормами. Тем не менее это остаётся **золотым стандартом** защиты.

Практические выводы и рекомендации

1 Выбор атаки зависит от цели

Для быстрой оценки устойчивости — PGD. Для поиска минимально заметных возмущений — C&W. Для анализа значимости признаков и разреженных атак — JSMA.

2 Вычислительный бюджет критичен

FGSM — для быстрого прототипирования. PGD — для стандартной оценки. C&W и JSMA — только когда требуется максимальная точность или интерпретируемость, и вычислительные ресурсы позволяют.


3 Ни одна защита не является полной

На практике ни один метод защиты не показал полной устойчивости к C&W-атакам. Это делает C&W одним из главных эталонов при оценке новых защитных механизмов.

4 FastJSMA расширяет применимость

Снижение сложности с $O(M^2 \times N)$ до $O(M\sqrt{N})$ при сохранении ~98% эффективности делает JSMA-подход практически применимым за пределами малоразмерных датасетов.

Связь методов: единая картина



Все три метода отвечают на разные ограничения FGSM и занимают свои ниши в арсенале исследователя безопасности машинного обучения.

Итоги лекции

PGD

Многошаговое обобщение FGSM с проекцией. Attack Success Rate 80–90%. Стандарт adversarial training. «Универсальный первопорядковый противник» (Мадри, 2018).

C&W

Строгая оптимизация минимальной дисторсии. Параметр κ управляет уверенностью. tanh-замена переменных. Обходит дефенсивную дистилляцию. Главный эталон защитных механизмов.

JSMA

Якобиан выхода вместо градиента потерь. Разреженные L_0 -атаки. Интерпретируемость. Квадратичная сложность, FastJSMA снижает до $O(M\sqrt{N})$ при ~98% эффективности.



Следующий шаг: атаки чёрного ящика и transferability — как adversarial примеры, созданные для одной модели, переносятся на другие.

SoK: Security and Privacy in Machine Learning

