



Чёрный ящик и трансферируемость атак

Transfer-based, score-based и decision-based методы adversarial-атак в условиях ограниченного доступа к целевой модели

ADVERSARIAL ML

ЛЕКЦИЯ 5

От белого ящика к чёрному: смена модели угроз

Белый ящик

Атакующий имеет полный доступ к архитектуре, параметрам и градиентам целевой модели. Именно на этой предпосылке строятся FGSM, PGD, C&W, JSMA — методы, рассмотренные в предыдущих лекциях.

На практике эта предпосылка **редко выполняется**.


Чёрный ящик

Коммерческие ML-сервисы — распознавание изображений, антифрод-системы, модерация контента — предоставляют внешнему пользователю **только интерфейс запроса**, скрывая внутреннее устройство модели.

Атакующий не имеет доступа к градиентам, весам и архитектуре целевой системы и может опираться только на её **наблюдаемое поведение**.

Три класса black-box атак

По объёму доступной информации о выходе модели чёрные ящики делятся на три категории. Убывание доступной информации от белого ящика до чистого decision-based сценария заставляет менять сам принцип построения атаки.




От прямого использования градиента — к его оценке — и, наконец, к геометрическому поиску решающей границы.

Трансферируемость adversarial-примеров

РАЗДЕЛ 1

Эмпирический феномен переносимости — фундамент всего класса transfer-based атак.



Эмпирический феномен переносимости

Adversarial-пример, построенный для обмана одной модели, с высокой вероятностью обманывает и другую модель — даже если та имеет отличную архитектуру и обучена на другом наборе данных.

Это свойство впервые подробно задокументировано **Szegedy et al.** и **Goodfellow et al.** и составляет содержательное основание для атак, не требующих доступа к самой целевой модели на этапе конструирования возмущения.

Разные архитектуры

Перенос работает между моделями с принципиально разными архитектурами — CNN, ResNet, ViT и др.

Разные данные

Суррогат может быть обучен на данных, отличных от обучающего набора целевой модели.

Без запросов к цели

Возмущение строится полностью на суррогате — целевая модель не запрашивается в процессе оптимизации.

Теория: кривизна многообразия данных

Manifold Attack Model


Современная теоретическая модель (так называемая «manifold attack model») формализует интуицию о переносимости и объясняет, почему adversarial-примеры переносятся между моделями даже тогда, когда суррогатная модель является **неточной аппроксимацией** целевой — вслед за более ранними эмпирическими наблюдениями Papernot et al.

Существование переносимых adversarial-примеров определяется «**кривизной**» **многообразия данных**: чем более гладкой и предсказуемой является геометрия решающих границ относительно данных, тем выше согласованность направлений уязвимости между разными моделями, обученными на одной задаче.

Практический вывод

Успех transfer-based атак упирается в **фундаментальное геометрическое свойство задачи**, а не только в качество суррогатной модели. Это объясняет, почему успех переноса эмпирически трудно улучшить далее определённого предела — потолок задан геометрией данных, а не выбором суррогата.

❏ Кривизна многообразия данных — фундаментальный предел переносимости атак, не зависящий от качества суррогата.



Согласованность ландшафтов потерь (Robustness Alignment)

Более прикладное объяснение эффективности переноса опирается на понятие **согласованности состязательных ландшафтов** (adversarial landscape alignment) между суррогатом и целью.

Устойчивый → Устойчивый

Adversarially trained суррогаты эффективно переносят атаку преимущественно на другие устойчивые целевые модели.


Обычный → Обычный

«Vanilla» суррогаты эффективно атакуют обычные (необученные на adversarial-примерах) цели.

Смешивание типов

Смешивание типов моделей (устойчивый суррогат → обычная цель и наоборот) заметно снижает успех переноса.

Защитное следствие: даже простое **PGD-обучение** может снизить успех продвинутых black-box атак на моделях ImageNet с примерно **90% до менее чем 4%**, независимо от типа атаки — перенос или прямая оценка запросами.



Transfer-based атаки: суррогатная модель

РАЗДЕЛ 2

Классическая транзитивная атака Papernot et al. (2017) — без единого «белоящичного» запроса к целевой модели.

Общая схема суррогатной атаки

Атакующий обучает локальную суррогатную (substitute) модель, имитирующую поведение целевой системы, а затем строит для неё обычную белоящичную атаку (например, FGSM) и переносит результат на цель.

01

Инициализация

Атакующий собирает небольшой начальный набор представительных примеров S_0 (например, 10 образцов на класс для MNIST). Примеры не обязаны принадлежать распределению обучающих данных цели.

02

Разметка через оракул

Текущий набор данных S_p отправляется на вход целевой модели (оракулу) O , которая возвращает метки $\tilde{O}(x)$

03

Обучение суррогата

Локальная модель F обучается на парах (вход, метка оракула), имитируя поведение целевой системы.

04

Якобиан-аугментация

Формируются новые синтетические примеры путём смещения вдоль направлений, наиболее чувствительных для суррогатной модели. Шаги повторяются до достаточного качества суррогата.

Якобиан-ориентированная аугментация данных

Формула аугментации

Новые синтетические примеры формируются по правилу:


$$S_{p+1} = \{\tilde{x} + \lambda_{p+1} \text{sign}(J_F[\tilde{O}(\tilde{x})]) : \tilde{x} \in S_p\} \cup S_p$$

где J_F — якобиан суррогатной модели по метке оракула, а λ_{p+1} — величина шага аугментации.

Зачем это нужно

Якобиан-ориентированная аугментация («Jacobian-based dataset augmentation») целенаправленно исследует область вблизи решающей границы, где суррогат наименее уверен.

Это повышает **согласованность границ суррогата и цели** при небольшом числе исходных примеров — ключевое преимущество метода перед случайной аугментацией.



Практическая эффективность и ограничения переноса

88% +

Успех атаки

Ошибочная классификация против Amazon и Google при всего 800 запросах к оракулу, используя даже простую логистическую регрессию в качестве суррогата.

800

Запросов к оракулу


Крайне низкая стоимость запросов — основная «стоимость» переносится на этап обучения суррогата, а не на итеративное уточнение возмущения.

Ключевое преимущество


Основная «стоимость» переносится на этап обучения суррогата (где запросы дешёвые), а не на этап итеративного уточнения возмущения непосредственно на целевой модели.

Ограничения

Transfer-based атаки **не гарантируют переноса**, особенно для целевых (targeted) атак, требующих конкретного целевого класса — устойчивость переноса заметно снижается по сравнению с нецелевыми атаками. Отсутствие доступа к целевой модели во время оптимизации означает субоптимальность найденного решения.



(a) DNN substitutes



(b) DNN substitutes

Real-World API AttacksThe attack achieved remarkable success rates against commercial services:


MetaMind DNN: 84.24% misclassification rate on MNIST adversarial examples

Amazon Machine Learning: 96.19% misclassification rate using logistic regression substitute

Google Cloud Prediction: 88.94% misclassification rate

Local GTSRB Oracle: 64.24-69.03% misclassification rates on traffic sign images

Эффективность атаки оценивается по количеству образцов, верно размеченных различными типами оракулов в процессе обучения суррогатной модели; это демонстрирует сходимость к эффективной генерации состязательных примеров.



Score-based атаки: оценка градиента через запросы

РАЗДЕЛ 3

Атакующий получает числовые оценки уверенности (вероятности softmax или логиты) по каждому классу, но не имеет доступа к градиентам.

Постановка задачи: score-based сценарий

Что доступно атакующему

Атакующий может отправлять запросы к модели и получать в ответ **числовые оценки уверенности** — вероятности softmax или логиты по каждому классу. Доступа к градиентам или внутренним параметрам нет.

Формальная задача

Задача атаки формулируется так же, как и в белоящичном случае: найти минимальное возмущение δ : $\|\delta\|_p \leq \epsilon$ приводящее к ошибочной классификации $\mathbf{f}(\mathbf{x} + \delta) \neq \mathbf{f}(\mathbf{x})$.

Принципиальное отличие: производные функции потерь по входу необходимо **оценивать через запросы**, а не вычислять напрямую через автодифференцирование.

ZOO: Zeroth Order Optimization

Атака ZOO адаптирует принцип C&W-атаки к чёрно-ящичному сценарию, заменяя точное вычисление градиента его **покоординатной оценкой методом конечных разностей**:

Формула оценки градиента

$$\frac{\partial L}{\partial x_i} \approx \frac{L(x + he_i) - L(x - he_i)}{2h}$$

где e_i — единичный вектор в направлении координаты i . Оценка требует **двух запросов к модели** на каждую координату.

Масштаб проблемы

Для изображения 299×299×3 из ImageNet прямая покоординатная оценка потребовала бы порядка **268 203 запросов** на одну оценку полного градиента.

Приёмы снижения стоимости

- **Понижение размерности** — атака работает в сжатом пространстве
- **Иерархическая атака** — постепенное уточнение от грубого к точному
- **Importance sampling** — выбор наиболее информативных координат вместо полного перебора

Результаты

На MNIST, CIFAR-10 и ImageNet ZOO достигает эффективности, сопоставимой с белоящичной C&W, значительно превосходя более ранние чёрно-ящичные методы на основе суррогатных моделей, и полностью избегает потери эффективности при переносе.

NES: Natural Evolution Strategies

NES — альтернативный, значительно более экономный по числу запросов способ оценки градиента, использующий **рандомизированный поиск** вместо по координатных конечных разностей.

Принцип работы

Вместо того чтобы пробовать каждую координату отдельно, NES **сэмплирует несколько точек** из гауссовского распределения поиска, центрированного в текущей точке x , запрашивает у модели значение функции потерь в каждой из них и усредняет случайные направления, взвешенные наблюдаемыми значениями потерь.

Формально:

$$\nabla_{\theta} J(\theta) \approx \frac{1}{\lambda} \sum_{k=1}^{\lambda} f(x_k) \nabla_{\theta} \log \pi(x_k | \theta)$$

Антитетическая выборка (antithetic sampling)

Практическая реализация использует **antithetic sampling**: каждое случайное направление u_i сопровождается симметричным направлением $-u_i$, что снижает дисперсию оценки при том же числе запросов:

$$g_{ES} = \frac{1}{2\sigma P} \sum_{i=1}^P (f(\theta + \sigma \epsilon_i) - f(\theta - \sigma \epsilon_i)) \epsilon_i$$

Направления, значительно увеличивающие функцию потерь, получают больший вес — разумная оценка градиента при существенно меньшем числе запросов, чем полный перебор координат.

Score-based атаки при ограниченном доступе

Дальнейшее развитие score-based атак учитывает более реалистичные ограничения промышленных API.



Ограниченный бюджет запросов

Query-limited setting: атака должна достигать цели при жёстко ограниченном числе обращений к модели.




Частичная информация о выходе

Доступ только к top-k вероятностям, а не ко всем классам — типичное ограничение коммерческих API.



Только метки без вероятностей


Работа Ilyas et al. показывает, что оценки на основе NES остаются работоспособными даже при существенном урезании информации о выходе модели.



Decision-based атаки: только итоговая метка

РАЗДЕЛ 4

Наиболее строгая и одновременно наиболее реалистичная модель угроз — без вероятностей, без оценок уверенности.



Постановка задачи: decision-based сценарий

Что видит атакующий

Только **финальная метка класса**, возвращаемая моделью.
Никаких вероятностей, никаких оценок уверенности — только бинарный или категориальный результат решения.

Почему это реалистично

Такая модель угроз типична для реальных производственных систем, которые из соображений безопасности **сознательно скрывают confidence-скор** от внешнего пользователя. Антифрод-системы, системы модерации контента, медицинские классификаторы — все они часто возвращают только итоговое решение.

Алгоритмический вызов

Без числовых оценок невозможно оценить градиент методами конечных разностей или NES. Требуется принципиально иной подход — **геометрический поиск** вдоль решающей границы.

Boundary Attack: случайное блуждание по границе

Boundary Attack (Brendel, Rauber, Bethge, 2017) — первая практическая decision-based атака, конкурентоспособная с лучшими градиентными белоящичными методами на задачах компьютерного зрения уровня ImageNet.

Ключевая идея

Вместо попытки оценить градиент атака выполняет **случайное блуждание вдоль границы** между областями адверсального и неадверсального решения, начиная из точки, которая уже гарантированно классифицируется неверно.

На каждой итерации решается задача отбора (rejection sampling), обеспечивающая одновременно два свойства: (1) сохранение примера в адверсальной области и (2) сокращение расстояния до исходного изображения.

Три компонента шага

1. **Ортогональное возмущение** — случайный шум проецируется на сферу вокруг исходного изображения так, чтобы расстояние до исходной точки сохранялось
2. **Шаг к цели** — небольшое смещение по направлению к исходному (неадверсальному) изображению, уменьшающее итоговое расстояние
3. **Динамическая адаптация шага** — параметры δ и ϵ настраиваются по принципу доверительной области (Trust Region)

Boundary Attack: динамическая адаптация шага

Принцип Trust Region

Оба параметра — размер общего возмущения δ и размер шага к цели ϵ — настраиваются динамически: если доля успешных ортогональных шагов близка к **50%**, шаг признаётся адекватным; если значительно ниже — шаг уменьшается; если выше — увеличивается.

Преимущества алгоритма


Алгоритм **не требует суррогатных моделей** и практически не нуждается в настройке гиперпараметров, что делает его удобным эталоном чёрно-ящичной устойчивости. Проверка локальной линейности границы решения — встроенная в ортогональный шаг.

Основное ограничение

Высокая стоимость запросов, обусловленная **случайным характером блуждания** по границе. Это открывает пространство для более эффективных алгоритмов, использующих явную оценку направления градиента на границе.

HopSkipJumpAttack: повышение эффективности запросов

HopSkipJumpAttack (HSJ, Chen et al., 2019) решает проблему высокой стоимости запросов Boundary Attack, вводя **явную оценку градиента непосредственно на границе** принятия решения с использованием пакета случайных векторов.



HopSkipJumpAttack: алгоритм

1 Поиск границы

Бинарным поиском между текущей точкой x и предыдущим адверсальным примером x'_{t-1} находится точка x_t , лежащая на границе решения. Бинарный поиск гарантирует точное нахождение граничной точки при логарифмическом числе запросов.

2 Оценка градиента на границе

С помощью батча случайных векторов оценивается направление градиента непосредственно в точке границы — в отличие от Boundary Attack, которая блуждает случайно, HSJ целенаправленно оценивает направление наискорейшего спуска.

3 Выбор шага и обновление

На основе оценённого градиента вычисляется размер шага и обновляется текущая точка x'_t для следующей итерации. Итерации повторяются до достижения заданного порога возмущения.

HopSkipJumpAttack: эффективность и охват

Против каких защит работает HSJ

- Дефенсивная дистилляция
- Region-based классификация
- Adversarial training
- Принципиально недифференцируемые модели: случайный лес, бинаризация

Сравнение с Boundary Attack

HopSkipJumpAttack требует **значительно меньше запросов** к целевой модели по сравнению с исходной Boundary Attack при сопоставимом или лучшем качестве атаки.

Ключевое преимущество — замена случайного блуждания на **направленный поиск** с явной оценкой градиента на границе, что резко повышает эффективность каждого запроса.

- ❏ HSJ — де-факто стандартный эталон для оценки устойчивости моделей в decision-based сценарии.

Decision-based атаки на табличных данных

Хотя decision-based атаки исходно разрабатывались для изображений, современные исследования адаптируют этот подход к **структурированным (табличным) данным**.

Специфика табличных данных

Непосредственное применение HopSkipJump требует специальной обработки **категориальных и смешанных признаков** для сохранения валидности изменённого примера.

Нельзя просто добавить вещественное возмущение к категориальному признаку.

Современный подход

Комбинирование безградиентной оценки направления с итеративным поиском границы в **SHAP-взвешенном пространстве признаков**: расширением радиуса вокруг исходной точки находится первая адверсальная точка, после чего бинарным поиском уточняется положение границы.

Алгоритм бинарного поиска границы

$$\mathbf{z}_{k+1} = \lambda_k \mathbf{u} + (1 - \lambda_k) \mathbf{v}, \lambda_k \in [0, 1]$$

с последующим обновлением:

- $\mathbf{u} \leftarrow \mathbf{z}_{k+1}$, если точка остаётся неадверсальной
- $\mathbf{v} \leftarrow \mathbf{z}_{k+1}$ в противном случае

до тех пор, пока расстояние между точками не станет меньше заданного порога τ .


Результаты

Успешность атаки свыше **90%** при относительно небольшом числе запросов даже на смешанных типах данных, включая табличные классификаторы и пайплайны с эмбедингами LLM.

Сравнительная сводка трёх классов атак

Критерий	Transfer-based	Score-based	Decision-based
Доступная информация	Никакой (только на этапе сбора данных для суррогата)	Confidence-баллы / вероятности классов	Только итоговая метка класса
Основной механизм	Обучение суррогата и перенос белоящичной атаки	Оценка градиента через запросы (конечные разности, NES)	Геометрический поиск вдоль решающей границы
Стоимость запросов	Низкая на целевую модель	Средняя–высокая, зависит от размерности	Высокая (Boundary) → умеренная (HSJ)
Основной риск	Слабый перенос для целевых атак; зависимость от кривизны многообразия	Дороговизна оценки градиента в высокой размерности	Медленная сходимость без оценки градиента (Boundary Attack)
Методы	Substitute model (Papernot et al.)	ZOO, NES	Boundary Attack, HopSkipJumpAttack

Визуальное сравнение: информация vs. стоимость запросов



По мере убывания доступной информации от белого ящика до decision-based сценария принципиально меняется алгоритмический инструментарий — от прямого использования градиента до геометрической навигации по решающей границе.

ZOO vs. NES: сравнение score-based методов

ZOO (Zeroth Order Optimization)


- Покоординатная оценка методом конечных разностей
- 2 запроса на каждую координату
- Для $299 \times 299 \times 3$: ~268 203 запросов на полный градиент
- Снижение стоимости: importance sampling, иерархия, понижение размерности
- Адаптация принципа C&W к чёрному ящику
- Эффективность сопоставима с белоящичной C&W

NES (Natural Evolution Strategies)

- Рандомизированный поиск из гауссовского распределения
- Оценка по батчу точек, а не по координатам
- Антитетическая выборка снижает дисперсию
- Значительно меньше запросов, чем полный перебор координат
- Работоспособен при доступе только к top-k вероятностям
- Устойчив к реалистичным ограничениям промышленных API


❏ NES предпочтителен в условиях жёсткого ограничения бюджета запросов; ZOO — когда важна точность оценки градиента по конкретным координатам.

Boundary Attack vs. HopSkipJumpAttack



Boundary Attack (2017)

Случайное блуждание вдоль границы решения. Начало из гарантированно адверсальной точки. Rejection sampling с двумя условиями: сохранение адверсальности и сокращение расстояния. Не требует суррогатов и настройки гиперпараметров. **Высокая стоимость запросов** из-за случайного характера блуждания.



HopSkipJumpAttack (2019)

Явная оценка градиента на границе с помощью батча случайных векторов. Три шага: бинарный поиск границы → оценка градиента → обновление точки. Работает против дефенсивной дистилляции, adversarial training, случайных лесов. **Значительно меньше запросов**, чем Boundary Attack.

Adversarial Training как универсальная защита

~90%

ASR без защиты

Attack Success Rate продвинутых black-box атак на необученных моделях ImageNet.

<4%

ASR с PGD-обучением

После применения PGD adversarial training (Мадри и др.) — независимо от типа атаки.

Практическое наблюдение: adversarial training существенно снижает успех как transfer-based, так и score-based/decision-based атак. Защитные меры, разработанные против белоящичных атак, **переносятся и на чёрно-ящичный сценарий**.

Спектр black-box сценариев

Уровень 4: Черный ящик (по решению)

Доступна только метка класса.
Методы: Boundary Attack, HSJ.

Уровень 3: Черный ящик (по оценкам)


Доступны оценки уверенности.
Методы: ZOO, NES.

Уровень 2: Черный ящик (перенос)

Нет доступа к цели; атака через суррогатную модель.

Уровень 1: Белый ящик

Полный доступ к градиентам, весам и архитектуре модели.




Модель угроз «чёрный ящик» не является единой категорией, а образует **спектр сценариев** с существенно разной доступной атакующему информацией, что напрямую определяет применимый алгоритмический инструментарий.

Ключевые алгоритмические принципы



Перенос через суррогат

Якобиан-аугментация данных для согласования границ суррогата и цели при минимуме запросов к оракулу.



Конечные разности (ZOO)

Покоординатная оценка градиента с importance sampling для снижения числа запросов в высокой размерности.



Эволюционные стратегии (NES)

Рандомизированный поиск с антитетической выборкой — разумная оценка градиента при минимальном числе запросов.



Геометрический поиск границы

Случайное блуждание (Boundary Attack) и направленный поиск с оценкой градиента на границе (HSJ).

Связь с предыдущими лекциями курса


Преемственность методов

ZOO адаптирует **C&W-атаку** к чёрному ящику. Transfer-based атаки используют **FGSM** на суррогате. Score-based и decision-based методы решают ту же задачу минимизации возмущения, что и белоящичные атаки — но без прямого доступа к градиентам.

Преемственность защит

PGD adversarial training (Мадри и др.), разработанное против белоящичных атак, обеспечивает защиту и в чёрно-ящичном сценарии — падение ASR с ~90% до < 4% на ImageNet. Это подчёркивает сквозную связность материала курса: защиты не специфичны для конкретного класса атак.

Расширение за пределы компьютерного зрения



Табличные данные

Decision-based атаки адаптированы для структурированных данных с категориальными и смешанными признаками. Бинарный поиск в SHAP-взвешенном пространстве признаков. Успешность свыше 90% при небольшом числе запросов.

Пайплайны с LLM

Современные методы работают с пайплайнами, включающими эмбединги больших языковых моделей – актуально для прикладных направлений защищённых систем.

Медицинский ИИ

Методы для смешанных типов данных напрямую связаны с задачами медицинской диагностики, где модели часто возвращают только итоговое решение без вероятностей.

Ключевые выводы лекции

- Чёрный ящик — это спектр, а не единая категория

Transfer-based, score-based и decision-based сценарии существенно различаются по доступной информации и требуют принципиально разных алгоритмических подходов.

- Оценка градиента — ключевая проблема score-based атак

ZOO и NES решают её по-разному: покоординатно и рандомизированно. NES предпочтителен при жёстком ограничении бюджета запросов.

- Трансферируемость определяется геометрией данных

Кривизна многообразия данных задаёт фундаментальный предел переносимости атак, не зависящий от качества суррогатной модели.

- Adversarial training защищает от всех классов атак

PGD-обучение снижает ASR с ~90% до менее 4% на ImageNet — независимо от типа чёрно-ящичной атаки.

Итог: от градиента к геометрии

Убывание доступной информации от белого ящика до decision-based сценария заставляет менять сам принцип построения атаки — от прямого использования градиента до его оценки и, наконец, до геометрического поиска решающей границы. Понимание этого спектра критически важно как для разработки атак, так и для проектирования устойчивых систем.

Transfer-based Суррогат + перенос	Score-based ZOO / NES
Decision-based Boundary / HSJ	

ADVERSARIAL ML

БЕЗОПАСНОСТЬ ML-СИСТЕМ

AI AND THE FUTURE OF NATIONAL SECURITY

Findings from a survey of 100+ national security practitioners on the opportunities and risks of advanced AI deployment in military, cybersecurity, intelligence, and CBRN

MARIAMI TKESHELASHVILI
RITIKA VERMA
BRIDGET WILLIAMS
REBECCA CEPAS DE CASTRO
SEPTEMBER 2026

IST Institute for
SECURITY + TECHNOLOGY

Литература

1. Papernot, N.; McDaniel, P.; Goodfellow, I.; Jha, S.; Celik, Z.B.; Swami, A. Practical black-box attacks against machine learning. In Proceedings of the 2017 ACM on Asia Conference on Computer and Communications Security (ASIA CCS), Abu Dhabi, United Arab Emirates, 2–6 April 2017; pp. 506–519. <https://doi.org/10.1145/3052973.3053009>.
2. Chen, P.-Y.; Zhang, H.; Sharma, Y.; Yi, J.; Hsieh, C.-J. ZOO: Zeroth order optimization based black-box attacks to deep neural networks without training substitute models. In Proceedings of the 10th ACM Workshop on Artificial Intelligence and Security (AISec '17), Dallas, TX, USA, 3 November 2017; pp. 15–26. <https://doi.org/10.1145/3128572.3140448>
3. Brendel, W.; Rauber, J.; Bethge, M. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models. In Proceedings of the 6th International Conference on Learning Representations (ICLR), Vancouver, BC, Canada, 30 April–3 May 2018. Available online: <https://openreview.net/forum?id=SyZI0GWCZ> (accessed on 13 September 2026).
4. Ilyas, A.; Engstrom, L.; Athalye, A.; Lin, J. Black-box adversarial attacks with limited queries and information. In Proceedings of the 35th International Conference on Machine Learning (ICML), Stockholm, Sweden, 10–15 July 2018; Proceedings of Machine Learning Research; Dy, J.; Krause, A., Eds.; PMLR: Stockholm, Sweden, 2018; Volume 80, pp. 2137–2146
5. Liu, G.; Zhao, L.; Yang, F.; Bian, J.; Qin, T.; Yu, N.; Liu, T.-Y. Trust region evolution strategies. In Proceedings of the AAAI Conference on Artificial Intelligence, Honolulu, HI, USA, 27 January–1 February 2019; Volume 33, pp. 4352–4359. <https://doi.org/10.1609/aaai.v33i01.33014352.ojs.aaai>
6. Meier, F.; Mujika, A.; Gauy, M.M.; Steger, A. Improving gradient estimation in evolutionary strategies with past descent directions. In Proceedings of the NeurIPS 2019 Workshop on Optimization for Machine Learning, Vancouver, BC, Canada, 13 December 2019. Available online: <https://arxiv.org/abs/1910.05268> (accessed on 13 September 2026).
7. Chen, J.; Jordan, M.I.; Wainwright, M.J. HopSkipJumpAttack: A query-efficient decision-based attack. In Proceedings of the 2020 IEEE Symposium on Security and Privacy (SP), San Francisco, CA, USA, 18–21 May 2020; pp. 1277–1294. <https://doi.org/10.1109/SP40000.2020.00045>.
8. Chen, Y.; Zhang, Y.; Huang, H.; Liu, Z.; Wang, Q. A theory of transfer-based black-box attacks: Explanation and implications. In Advances in Neural Information Processing Systems 36 (NeurIPS 2023); Curran Associates, Inc.: New Orleans, LA, USA, 2023. Available online: https://proceedings.neurips.cc/paper_files/paper/2023/hash/2d0842550e6d92b0e27e7e810b1a4792-Abstract-Conference.html (accessed on 13 September 2026)