


Физические атаки в реальном мире

Adversarial patches, дорожные знаки, состязательная одежда — конспект лекции по физической робастности систем компьютерного зрения

ТОЛЬКО ДЛЯ ИЗОЛИРОВАННЫХ ИССЛЕДОВАТЕЛЬСКИХ СРЕД



Этическая граница

⊗ Материал предназначен исключительно для анализа рисков и тестирования устойчивости в изолированных учебных или явно разрешённых исследовательских средах. Применение к дорожной инфраструктуре, системам наблюдения, транспорту и иным реальным системам без явного разрешения недопустимо.

Учебная цель

Понять, почему состязательные возмущения, работоспособные в цифровом изображении, иногда сохраняют эффект после печати, размещения на объекте и съёмки камерой.

Модель угроз

Освоить ключевые механизмы робастности физических атак и понять, как правильно формулировать сценарии угроз для реальных систем восприятия.

Меры защиты

Изучить системные подходы к защите: от робастного обучения и аугментаций до мультисенсорного слияния и временной агрегации.

От цифрового изображения к физическому миру

В обычной постановке adversarial ML возмущение добавляется непосредственно к цифровому входу модели:

$$x_{adv} = x + \delta, \quad \|\delta\|_p \leq \varepsilon$$

В физическом мире объект с возмущением сначала **печатается или изготавливается**, затем наблюдается камерой. Вход модели определяется не только исходным шаблоном, но и сложной цепочкой физических преобразований:

$$x_{cam} = C(S(x, \delta; \theta_{scene}))$$

Здесь S описывает сцену и поверхность объекта, C — камеру и предобработку, а θ_{scene} включает геометрию съёмки, освещение, фон, расстояние, угол обзора, размытие, окклюзии и свойства печати. Поэтому физическая атака должна быть устойчивой не к одному входу, а к **распределению возможных условий наблюдения** — это главный переход от цифровой к физической постановке.

Почему физический сценарий сложнее



Перспектива и масштаб

Объект занимает разное число пикселей при изменении расстояния и угла камеры. Один и тот же патч может быть слишком мал или искажён до неузнаваемости.



Освещённость

Тени, отражения, цветовая температура и автоматическая экспозиция меняют цветовые значения — то, что выглядит ярко-красным в студии, может стать тёмно-коричневым на улице.



Печать и материал

Принтер имеет ограниченную цветовую гамму; ткань, бумага, пластик и краска отражают свет по-разному. Мелкие детали теряются при печати.



Камера и обработка

Шум сенсора, компрессия, автофокус, blur, баланс белого и ресайзинг меняют картинку до поступления в нейросеть.



Частичная видимость

Часть патча может быть закрыта, находиться вне кадра, быть смятой или деформированной — особенно критично для носимых объектов.



Временная динамика

В видеопотоке меняются поза, положение, дистанция и фон. Успешная атака на одиночный кадр не доказывает работоспособность в реальной среде.

 Успешная атака на одиночный цифровой кадр не является доказательством работоспособности в реальной среде.

Модель угроз: активы и цели атакующего

Атакующий может стремиться к различным результатам в зависимости от типа атакуемой системы. Для классификатора дорожного знака результатом является метка класса. Для детектора объектов результат сложнее: множество ограничивающих рамок, классов и confidence-значений после NMS.

Целевая ошибка классификации

$f(x_{cam}) = y_{target}$ — модель выдаёт заранее выбранный класс вместо правильного.

Нецелевая ошибка

$f(x_{cam}) \neq y_{true}$ — любая ошибка классификации без фиксации конкретного класса.

Disappearance / Hiding attack

Сделать объект незамеченным детектором — рамка не появляется или подавляется на стадии NMS.

Fabrication attack

Вызвать ложное обнаружение объекта выбранного класса — детектор «видит» несуществующий объект.

Снижение confidence

Уменьшить уверенность модели в правильном классе ниже порога принятия решения, не обязательно меняя итоговую метку.

Возможности атакующего: компоненты модели угроз

Модель угроз должна явно фиксировать все параметры атакующего. Неполная спецификация делает оценку устойчивости нерепрезентативной.

Компонент	Возможные варианты
Знание модели	White-box, transfer-based с surrogate, ограниченный black-box
Место возмущения	Свободное в кадре, локализованное на объекте, носимое на одежде
Форма	Прямоугольный патч, набор наклеек, текстура поверхности
Физический бюджет	Площадь, допустимые цвета, материал, расстояние, заметность
Цель	Targeted, untargeted, hiding, fabrication
Сценарий	Статическая фотография, проход/проезд, видеопоток, несколько камер

Метрики оценки физических атак

ASR

Attack Success Rate

Доля сцен/кадров, в которых выполнено условие атаки. Основная метрика эффективности.

R-ASR

Robust ASR

ASR, усреднённый по условиям съёмки: углам, расстояниям, освещению, фонам.

mAP

Clean mAP

Качество системы без патча. Необходимо контролировать, чтобы система исходно была работоспособна.

Физическая реализуемость

- Размер и площадь патча
- Цветовая гамма и возможность печати
- Устойчивость к деформации

Stealth / Заметность

Насколько изменение заметно человеку. Эта метрика **не тождественна** норме L_p — патч может быть замечен визуально, но иметь малую норму, и наоборот. Также учитывается query cost — число запросов в чёрно-ящикном сценарии.

Adversarial Patch: основная идея

Adversarial patch — **локализованный рисунок p** , который размещается в части сцены. В отличие от малой, распределённой по всем пикселям добавки δ , патч может быть хорошо заметен человеку, но занимает ограниченную область.

Классическая работа **Brown et al. (2017)** сформулировала патчи как *универсальные, робастные и целевые*: один патч может навязывать выбранную метку во множестве сцен, положений и преобразований.

Оператор наложения патча:

$$x' = A(x, p, l, t)$$

где l — положение патча, t — геометрическое/фотометрическое преобразование, а A учитывает маску и вставку в изображение.

Универсальность

Один патч предназначен для множества исходных сцен, а не для одной конкретной картинки.

Целевое действие

Классификатор склоняется к заранее выбранному классу независимо от исходного содержания сцены.

Локальность

Изменяется ограниченная зона — это делает атаку физически реализуемой, но не обязательно незаметной.

Expectation over Transformation (EOT)

Чтобы патч был устойчивым к реальным условиям наблюдения, оптимизируется **ожидаемая функция потерь по распределению преобразований**:

$$p^* = \arg \max_p \mathbb{E}_{x \sim \mathcal{D}, t \sim \mathcal{T}, l \sim \mathcal{L}} [\mathcal{L}(f(A(x, t(p), l)), y_{target})]$$

Для скрывающей атаки цель меняется: требуется уменьшить score обнаружения целевого объекта или нарушить выполнение условия детекции.

Распределение преобразований $\mathcal{T}$ обычно включает:

- Поворот и изменение масштаба
- Перенос по кадру
- Перспективная деформация
- Изменение яркости, контраста, насыщенности
- Шум, blur и JPEG-компрессия
- Случайные окклюзии
- Иногда модель печати и камеры

📌 Интуиция EOT: патч не подгоняется под один идеальный кадр. На каждом шаге оптимизации он видится модели в новом виртуальном физическом условии. Успешный патч должен сохранять полезный для атаки сигнал **в среднем** по этим условиям.

Ограничения adversarial patches

Патчи не являются магическим универсальным средством. Их эффективность существенно зависит от множества факторов, которые необходимо учитывать при оценке устойчивости.

Чувствительность к условиям съёмки

Эффект чувствителен к размеру патча в кадре, углу, расстоянию и освещению. Небольшое изменение дистанции или поворот камеры могут резко снизить ASR.

Ограниченная переносимость


Разные детекторы, версии моделей и алгоритмы предобработки дают разную переносимость. Патч, обученный на одной архитектуре, может не работать на другой.

Неполнота модели мира

Условия оптимизации могут не покрыть реальную среду. Печать, сжатие ткани и частичная окклюзия заметно уменьшают устойчивость.

Заметность

Крупный высококонтрастный патч может быть легко обнаружен человеком или отдельной системой контроля — это ограничивает практическую применимость.





Физические атаки на дорожные знаки

Распознавание знаков — компонент систем **ADAS**, **автономного транспорта** и **дорожной аналитики**. Ошибка в интерпретации знака способна иметь высокий потенциальный ущерб, поэтому это естественный тест-кейс для анализа физической робастности.

Работа **Eykholt et al. (CVPR 2018)** предложила метод **RP2 (Robust Physical Perturbations)** и показала целевые атаки на реальные дорожные знаки с учётом условий физической съёмки. Авторы рассматривали, в частности, чёрно-белые наклейки на знаке STOP.

100%

Лабораторные изображения

Целевых ошибок в лабораторных изображениях для одной атакуемой модели в конкретной экспериментальной конфигурации.

84.8%

Полевое видео

Кадров с целевой ошибкой в полевом видео с движущегося автомобиля для одной атакуемой модели.



Эти цифры относятся к условиям и моделям данного исследования, а не ко всем современным дорожным системам.

RP2: Robust Physical Perturbations

Обобщённая идея RP2 — оптимизировать возмущение **одновременно по нескольким фотографиям и преобразованиям объекта**:

$$\delta^* = \arg \min_{\delta} \sum_{i=1}^N \mathcal{L}(f(T_i(x + M \odot \delta)), y_{target}) + \lambda R(\delta)$$

Компоненты формулы

- T_i — наблюдаемые или синтетически смоделированные условия съёмки
- M — маска допустимой области изменения
- $R(\delta)$ — регуляризация для ограничения печатаемости, заметности или гладкости
- λ — коэффициент компромисса между атакой и ограничениями

Роль маски

В физическом дизайне принципиально важна маска: нельзя изменять всё изображение. Возмущение размещается на знаке как постер или набор наклеек. Это приближает цифровую постановку к реальным ограничениям и делает атаку физически реализуемой.

Классификатор vs. детектор: разные задачи атаки

Нельзя напрямую переносить выводы с классификатора дорожных знаков на детектор объектов — это принципиально разные задачи с разными целями атаки.

Характеристика	Классификатор	Детектор объектов
Вход	Обычно заранее выделенный объект	Полный кадр сцены
Выход	Одна метка класса	Рамки, метки и confidence
Цель атаки	Изменить метку знака	Скрыть знак, изменить класс или создать ложный объект
Главная трудность	Ошибка класса	Совместное нарушение локализации, классификации и NMS

В работе по физическим атакам на детекторы (Eykholt et al., WOOT 2018) рассматривалась **disappearance attack** для STOP-знака. В контролируемом видео YOLOv2 не распознавал модифицированные знаки более чем в **85% кадров**; в наружном эксперименте эффективность зависела от типа физического возмущения и была ниже. Работа также исследовала переносимость на Faster R-CNN.

Что следует и чего не следует заключать

✓ Корректный вывод

Физически реализуемые локальные изменения могут быть **существенным риском для отдельных моделей и сценариев**, поэтому устойчивость нужно проверять под реалистичными преобразованиями. Исследования RP2 демонстрируют реальную уязвимость конкретных архитектур в конкретных условиях.

× Некорректный вывод

«Небольшая наклейка гарантированно обманет все автомобили». Реальная система обычно включает **несколько сенсоров, временную агрегацию, картографические данные, правила безопасности и мониторинг достоверности**. Результаты одного исследования нельзя экстраполировать на всю автономную систему.

- Каждый вывод об эффективности физической атаки должен быть строго ограничен конкретной моделью, условиями съёмки и протоколом эксперимента.

Состязательная одежда: особенности носимых объектов

Одежда — **не жёсткая плоская поверхность**. Перенос патча с плоского изображения на футболку нельзя моделировать только поворотом и масштабированием.



Деформации ткани

Неаффинные деформации из-за позы и движения человека, складки и растяжение ткани — принципиально иная геометрия по сравнению с жёстким знаком.




Самоокклюзия

Руки, волосы, предметы частично перекрывают патч. Степень окклюзии непредсказуемо меняется с каждым движением.



Динамика наблюдения

Смена ракурса и масштаба, вариативность фона, временная динамика видеопотока — всё это создаёт распределение условий, намного шире, чем для статичного знака.



Adversarial T-shirt: Xu et al. (ECCV 2020)

Работа Xu et al. предложила физически реализуемую состязательную футболку для обхода детекторов людей. Ключевой методический вклад — включение **модели деформации ткани** в цикл оптимизации.

$$\mathbb{E}_{t \sim \mathcal{T}, w \sim \mathcal{W}} [\mathcal{L}(f(A(x, t(W_w(p))))), \text{hide}]$$

Вместо патча p в плоскости оптимизируется его поведение после преобразования **WTPS** (thin-plate spline), где W — распределение деформаций ткани.

74%

Цифровой мир

Успех атаки против YOLOv2 в цифровом эксперименте данной постановки.

57%

Физический мир

Успех атаки против YOLOv2 в физическом эксперименте данной постановки.

⚠ Это экспериментальные результаты конкретной постановки, а не универсальная характеристика атак на системы видеонаблюдения.

Что атакуется в детекторе людей

Для детектора людей атака направлена не на одну метку, а на комплекс взаимосвязанных выходов. Защиту необходимо оценивать не только по top-1 accuracy, но и по recall, precision, mAP, частоте пропусков и устойчивости треков во времени.

1

Снижение score класса «person»

Уменьшить уверенность детектора в рамках, перекрывающих человека, ниже порога принятия решения.

2

Ухудшение локализации рамки

Сместить или деформировать предсказанную рамку так, чтобы IoU с истинной рамкой упал ниже порога.

3

Подавление рамки через NMS

Вызвать появление ложных рамок, которые подавят правильную рамку на стадии Non-Maximum Suppression.

4

Нарушение трекинга

Снизить стабильность трекинга при последовательной обработке кадров — объект «исчезает» и «появляется» без физической причины.

Почему результаты атак на одежду часто нестабильны

→ Размер патча в кадре

Патч может оказаться слишком мал в кадре при большом расстоянии до камеры — сигнал теряется.

→ Расхождение модели деформации

Деформации реальной ткани могут существенно отличаться от модели TPS, использованной при оптимизации.

→ Аугментации при обучении детектора

Детектор обучен с сильными аугментациями или на похожих текстурах — патч не является аномалией для модели.

→ Многокамерное наблюдение

Несколько камер наблюдают объект под разными углами — атака должна работать одновременно для всех ракурсов.


→ Временная память трекера

Видеотрекер использует информацию из предыдущих кадров — даже если патч сработал в одном кадре, трекер может «восстановить» объект.

Методически корректное исследование требует множества людей, поз, расстояний, фонов, освещений, камер и повторов — **одного удачного фото недостаточно.**

От цифровой оптимизации к физической реализации

Физически осмысленный цикл эксперимента включает девять последовательных этапов, каждый из которых критически важен для получения воспроизводимых и интерпретируемых результатов.



Printability и цветовые ограничения

RGB-значение, полученное в оптимизации, не обязано воспроизводиться принтером и камерой. Для приближения к печатаемости используют специальные техники.



Ограничение палитры

Проецирование оптимизируемых значений на множество физически воспроизводимых цветов конкретного принтера и материала.



Total Variation

Регуляризация TV исключает чрезмерно высокочастотные текстуры, которые теряются при печати и не воспроизводятся на ткани.



Non-printability score

Расстояние до доступных печатных цветов — штраф за использование цветов, которые принтер не может воспроизвести точно.



Калибровка цепочки

Калибровка «принтер → материал → камера» и аугментации яркости, гаммы и баланса белого для учёта реальных условий съёмки.



Смысл таких ограничений не в маскировке атаки, а в том, чтобы результаты оценки устойчивости не опирались на несуществующие физические цвета или микродетали.

Digital–Physical Gap: источники разрыва

Разрыв между цифровым и физическим эффектом возникает, когда оптимизация использует **неполную модель мира**. Чем ближе распределение преобразований при обучении патча к реальному распределению наблюдений, тем выше вероятность переноса — однако полного совпадения обычно нет.



Почему нет одной достаточной защиты

Защита должна адресовать разные уровни: **данные, модель, интерфейс, сенсоры и эксплуатацию**. Одна эвристика редко даёт надёжную защиту против всех патчей, условий и адаптивных атак.

Уровень данных

Аугментации, реалистичные преобразования, out-of-distribution примеры в обучении.

Уровень модели

Adversarial training, patch-aware обучение, мультизадачное обучение.

Уровень интерфейса

Детектирование и локализация патчей, анализ аномалий в предсказаниях.

Уровень сенсоров

Мультисенсорное слияние: камера, лидар, радар, инерциальные данные.

Уровень эксплуатации

Временная агрегация, контекстные проверки, мониторинг, fail-safe.

Меры защиты на уровне обучения модели

Adversarial training

Включение реалистично преобразованных состязательных примеров и патчей в обучение. Модель учится быть устойчивой к тем же преобразованиям, которые используются при атаке.

Аугментации

Перспектива, blur, сжатие, погодные/световые эффекты, окклюзии, масштаб, цветовые сдвиги — широкое покрытие условий наблюдения снижает чувствительность к конкретным преобразованиям.

Patch-aware training

Разнообразные локальные вставки, CutOut, Random Erasing, synthetic patches с корректной валидацией. Модель учится игнорировать локальные аномалии.

Мультизадачное обучение

Совместный контроль детекции, сегментации, геометрии и временной согласованности. Атаке сложнее одновременно нарушить все задачи.

Out-of-distribution оценка

Разделять данные не только случайно, но и по камерам, локациям, погоде, субъектам и времени — это выявляет реальную обобщаемость модели.

Детектирование и локализация патчей

Подходы к детектированию

- Поиск аномально высококонтрастных/повторяющихся локальных текстур
- Сегментация подозрительных областей
- Проверка устойчивости предсказания при маскировании, кропах и преобразованиях
- Детекторы патчей, обученные на разнообразных реалистичных патчах
- Анализ спектральных, текстурных и семантических несоответствий

Ключевое ограничение

Защитный детектор **сам может быть атакован**. Адаптивный противник, знающий о детекторе патчей, может оптимизировать атаку так, чтобы обойти и основную модель, и защитный детектор одновременно.

Поэтому оценка защиты **должна включать адаптивный сценарий** — тестирование против атакующего, который знает о применяемой защите.

Системная защита: транспорт и безопасность

Для транспортных и охранных систем системная защита особенно критична. Ключевой принцип: различать «модель уверенно выдала класс» и «система имеет достаточные основания выполнить действие».



Мультисенсорное слияние

Камера, лидар, радар, инерциальные данные — атака на один сенсор не нарушает согласованность всей системы.



Временная агрегация

Решение на серии кадров, а не на одном кадре. Физический объект не должен исчезать/появляться без правдоподобной динамики.



Контекстные проверки

Дорожная карта, геометрия, допустимые места расположения знаков — контекст ограничивает пространство правдоподобных интерпретаций.



Неопределённость и fail-safe

Снижение доверия к одиночному противоречивому наблюдению, мониторинг аномальных confidence-профилей, журналирование и оценка сдвига данных.

Протокол оценки устойчивости

Минимально убедительная оценка физической атаки должна содержать исчерпывающую документацию всех условий эксперимента. Без этого результаты невозможно воспроизвести или критически проверить.

Описание системы и атаки

- Модель, версия, предобработка, пороги и метрики
- Модель угроз и ограничения на патч
- Цифровые и физические условия эксперимента
- Переносимость между архитектурами

Статистика и условия

- Число сцен, кадров и независимых повторов
- Распределения углов, расстояний, освещённости, фонов
- Clean performance и robust performance
- Доверительные интервалы и случаи неуспеха

📌 Защитные меры и их оценка против адаптивного противника должны быть включены в отчёт наравне с результатами атаки.

Сравнение трёх классов физических атак

Свойство	Универсальный patch	Дорожный знак / RP2	Состязательная одежда
Тип объекта	Локальная область сцены	Жёсткий объект со знакомой геометрией	Не-жёсткая поверхность на движущемся человеке
Тип модели	Часто классификатор, иногда детектор	Классификатор и/или детектор знаков	Детектор людей и видеотрекинг
Главная робастность	Сцена, положение, масштаб, поворот	Угол, расстояние, освещение, физическое размещение	Поза, складки, растяжение, окклюзия, динамика
Основной механизм	EOT и локальная вставка	EOT/RP2 и маска физически допустимой области	EOT + модель не-жёсткой деформации (TPS)
Ключевая защита	Patch-aware обучение, детектирование	Сенсорное слияние, контекст, временная проверка	Многокадровый анализ, несколько камер, robust detection

Риски интерпретации по классам атак

Универсальный patch

Риск: переобобщение с одной модели. Патч, обученный на одном классификаторе, может не переноситься на другие архитектуры, версии или условия предобработки. Результаты нельзя экстраполировать без явного тестирования переносимости.

Дорожный знак / RP2

Риск: нельзя переносить вывод на всю автономную систему. Успех на одном классификаторе знаков не означает уязвимости полной системы ADAS с мультисенсорным слиянием и временной агрегацией.

Состязательная одежда

Риск: нельзя судить по одному кадру без видеооценки. Успех на статичной фотографии не доказывает эффективности в видеопотоке с трекером, использующим историю наблюдений.

Вывод 1: Атака на канал восприятия

Физическая атака — это атака на весь канал восприятия

Физическая состязательная атака — это атака на весь канал восприятия, а не на массив RGB-пикселей. **Печать, геометрия, освещение, камера и временная динамика** определяют итоговый вход модели.

Это означает, что оценка устойчивости должна моделировать весь канал, а не только цифровую часть. Оптимизация в пиксельном пространстве без учёта физических преобразований даёт нерепрезентативные результаты.

Вывод 2–3: EOT и дорожные знаки

Вывод 2: Adversarial patch и EOT

Adversarial patch делает физическую постановку реалистичнее за счёт **локального, потенциально печатаемого изменения**. Его ключевой механизм робастности — оптимизация по распределению преобразований EOT. Без EOT патч переобучается на один идеальный кадр и теряет эффект в реальных условиях.

Вывод 3: Дорожные знаки и интерпретация

Дорожные знаки показывают **высокий прикладной риск**, но исследования нужно интерпретировать строго в пределах конкретной модели, условий съёмки и протокола эксперимента. Результаты RP2 не переносятся автоматически на современные многосенсорные системы.

Вывод 4–5: Одежда и digital–physical gap


Вывод 4: Состязательная одежда

Состязательная одежда существенно сложнее плоского патча из-за **не-жёстких деформаций, позы, окклюзий и видеодинамики**. Модель ткани (например, TPS) должна быть частью постановки — без неё цифровые результаты не переносятся в физический мир.

Вывод 5: Digital–physical gap

Цифровой успех **не эквивалентен физическому успеху**. Разрыв digital–physical — не исключение, а ожидаемая часть процесса. Его источники: неполная модель мира в EOT, потери при печати, реальные деформации и различия в production-пайплайне.

Purdue Model for ICS Security: Layers and Zones of Defense



Вывод 6: Системная защита

Защита должна быть системной

Робастное обучение, реалистичные аугментации, детектирование патчей, временная согласованность, контекст и мультисенсорность взаимно дополняют друг друга. Ни одна из этих мер в отдельности не обеспечивает надёжной защиты против адаптивного противника.

Вопросы для самопроверки

01

Патч vs. Lp-норма

Чем ограничение патча по площади принципиально отличается от ограничения Lp-нормы по всему изображению?

03

Типы атак

Чем отличаются targeted misclassification, disappearance и fabrication attack по целям и механизмам?

05

Digital–physical gap

Какие источники образуют разрыв между цифровым и физическим эффектом атаки?

02

Роль EOT

Почему EOT является центральным элементом физической робастности? Какие преобразования включить для знака, а какие — дополнительно для футболки?

04

Одно изображение vs. видеопоток

Почему вывод по успешности атаки на одиночном изображении недостаточен для детектора в видеопотоке?

06

Воспроизводимость оценки

Почему мультисенсорное слияние и временная агрегация повышают устойчивость, но не гарантируют абсолютную безопасность? Какие элементы должны быть в отчёте для воспроизводимости?

Ключевые публикации



Brown et al. —
Adversarial Patch
(2017)

Универсальные, робастные, целевые патчи, пригодные для печати и размещения в сцене. Первая систематическая формулировка физически реализуемых патчей с EOT.



Eykholt et al. —
RP2 (CVPR 2018)

Robust Physical Perturbations и эксперименты с дорожными знаками. Целевые атаки на реальные знаки STOP с учётом условий физической съёмки.



Eykholt et al. —
Object Detectors
(WOOT 2018)

Физические атаки на детекторы объектов, включая disappearance attack для STOP-знака. Исследование переносимости на Faster R-CNN.



Xu et al. —
Adversarial T-shirt
(ECCV 2020)

Моделирование деформаций ткани (TPS) для атак на детекторы людей. 74% успеха в цифровом и 57% в физическом мире против YOLOv2.

Обзор: *Adversarial Examples in the Physical World: A Survey (2024)* — систематизация современного состояния области.

Итог: физические атаки и устойчивость систем

Физическая постановка

Атака на весь канал восприятия. EOT — ключевой механизм робастности патча к реальным условиям.

Дорожные знаки

Высокий прикладной риск, но выводы строго ограничены конкретной моделью и протоколом.

Состязательная одежда

Сложнее плоского патча: деформации ткани, поза, окклюзии, видеодинамика требуют модели TPS.

Digital–physical gap

Цифровой успех $\neq$ физический успех. Разрыв — ожидаемая часть процесса, а не исключение.

Системная защита

Робастное обучение + аугментации + детектирование патчей + мультисенсорность + временная агрегация.

❏ Применение изученных методов допустимо только в изолированных учебных или явно разрешённых исследовательских средах.